SAPIENTIA ERDÉLYI MAGYAR TUDOMÁNYEGYETEM
MAROSVÁSÁRHELYI KAR
SZÁMÍTÁSTECHNIKA SZAK

NÖVÉNYMAGOK VALÓS IDEJŰ FELISMERÉSÉRE ÉS FIZIKAI TULAJDONSÁGAIK BECSLÉSÉRE ALKALMAS MOBIL-APPLIKÁCIÓ TERVEZÉSE ÉS KIVITELEZÉSE

Témavezető:
Dr. Brassai Sándor Tihamér,
egyetemi docens

Végzős hallgató:
Bíró Apor

2024

1. Bevezető

A Számítástechnikában, a Mesterséges Intelligencia korunkban hatalmas figyelemnek őrvend. Ugyebár az MI ezen a szakterületen már elég régóta jelen van, úgymond itt "született", de mégis csak az utóbbi pár évben ért el olyan áttöréseket - gondolok akár a GPT nyelvi modellekre, kép- és formaalkotó algoritmusokra, illetve pontos és könnyen használható képfelismerő algoritmusokra, mint például a YOLO - amelyek már nem csak a számítógéptudósok és -mérnökök figyelmét, hanem a más szakterületekben, mint például orvostudományokban, társadalomtudományokban vagy éppenséggel agrártudományokban munkálkodók figyelmét is felkeltették.

A cél egy olyan mesterséges neurális hálózatokat alkalmazó szoftver megvalósítása volt, amely valós időben, egy okostelefon kameráján keresztül képes felismerni egy képkockán lévő különböző magfajtát, ezeket osztályozni, ezek után pedig képes legyen becslést végezni ezeknek a méretére, tömegére, térfogatára illetve ebből fakadóan, az egymás közötti arányaikra. Ezt az applikációt felhasználási szempontból majd alkalmazni lehessen a mezőgazdaságban, olyas értelemben például hogy elkülönítsen több magfajtát, így ki tudja szűrni a nem egy fajhoz tartozó magokat vagy például mérleg nélkül tudjon tömeget becsülni.

Azért ezt a MI-hoz kapcsolódó témát választottam, mert amióta a Mesterséges Intelligencia tantárgy keretein belül mélyebb betekintést nyertem ennek a működésébe, történetébe, felhasználási területeibe, és a szerteágazó sok lehetőségébe, elkezdett kifejezetten érdekelni. Hirtelenjében még nem tudtam magamtól elképzelni, hogy milyen témát keressek amely érdekelne is, meg lenne benne potenciális felhasználási lehetőség, ezért témavezetőmtől kértem segítséget aki MI gyakorlat tanárom is volt. Ő tartotta a kapcsolatot a Kertészmérnöki tanszék tanáraival és egyeztetett velük, hogy milyen projekteket lehetne közösen kezdeményezni, amelyekben ők is asszisztálhatnának. Az egyik ötlet egy növényfelismerés alapján működő gyomláló-robot, a másik ötlet pedig ez a magfelismerő szoftver volt. Eredetileg a robotot akartuk megcsinálni, a tavalyi évben azt a dolgozatot is választottuk, de mivel nem sikerült elég időt szentelni azon a nyáron a tanítóhalmaz gyűjtésnek, ezért inkább ennek a projektnek fogtam neki.

Hatalmas köszönetet szeretnék mondani ezúton is vezető tanáromnak, Dr. Brassai Sándor Tihamér tanár úrnak a szakmai segítségért és útmutatásért, akinek volt türelme hozzám, akkor is amikor néha nehezen munkálkodtam, Dr. Biró-Janka Béla tanár úrnak a kertészmérnöki tanszékről,

végül de nem utolsó sorban pedig Kelemen Tamás másodéves kertészmérnök szakos hallgatónak a tanítóhalmazok elkészítésében való segédkezésért.

2. Szakirodalmi tanulmány és elméleti megalapozás

Kezdetleges elméleti megalapozásként szolgált a harmad év második félévében tanult Mesterséges Intelligencia tantárgy, amely lefektette az alapokat. Ekkor bővebben tanulhattam a Konvolúciós Neurális Hálózatok működéséről, illetve alkalmazásukról, sőt ebből a félév végén projektet is kellett készítsek.

2.1. Növénymag felismerésre alkalmas algoritmusok

2.1.1. YOLO objektumdetektáló algoritmusok

Szakirodalmi tanulmányozást legelőször a nyári gyakorlatom alatt kezdtem el, ekkor még az terv az volt, hogy egy gyomnövény felismerő programot kell készítsek. Ekkor ismerkedtem meg a YOLO (You Only Look Once) algoritmussal. A YOLO az egyik legnépszerűbb objektumfelismerő algoritmus, amint a legtöbb ehhez hasonló, CNN-ek (Konvolúciós Neurális Hálózat) felhasználásával működik. Egyszerű a használata, a tanítása, az alkalmazása. Emellett az algoritmus gyors, valós idejű működést tesz lehetővé, ami azt jelenti, hogy képes az objektumok felismerésére szinte azonnali. Készítettem erre még akkor egy egyszerűbb kis programot, mely videóról tudta felismerni a Százszorszép virágait, ez bizonyította az előbb említett tulajdonságait.

Amikor végleg eldöntöttem, hogy a jelenlegi projekttel fogok foglalkozni, a képfelismerő algoritmusok magokon való alkalmazásainak tanulmányozására fektettem legelőször időt. A tanulmányok között szintén rengeteg YOLO-s projekt volt. Konkrétan a rengeteg YOLO-t alkalmazó dolgozat közül alig lehetett találni más technológiákra összpontosító tanulmányokat. Arra a következtetésre jutottam, hogy mivel már amikor legelőször kipróbáltam a YOLO-t és saját szememmel láttam, hogy milyen pontos muszáj szerepeljen a dolgozatomban. A következőkben részletesebb kutatást végeztem magáról a YOLO algoritmusról, illetve alkalmazásáról a magfelismerés terén.

Az első YOLO 2015-ben jelent meg. Ez a verzió még nem ért el akkora ismeretséget és felhasználást mint az utódai. Az első verzióban munkálkodó CNN 24 konvolúciós réteget és utána 2

teljesen kapcsolt réteget tartalmazott, ennek volt két hibája: a pontatlan pozícionálás, illetve más akkori módszerekkel összehasonlítva az alacsonyabb visszahívási arány, a második verzióban ezeket a hibákat kijavították[1].

Ezeknek ellenére kezdete volt egy "dinasztiának", amely a mai napig uralja a képfelismerés iránt érdeklődők figyelmét. A 2.1.1.1.-ik ábrán látható, hogy 2016-tól 2021-ig hogyan tornászta fel magát ez az algoritmus a csúcsra a népszerűséget tekintve[1].

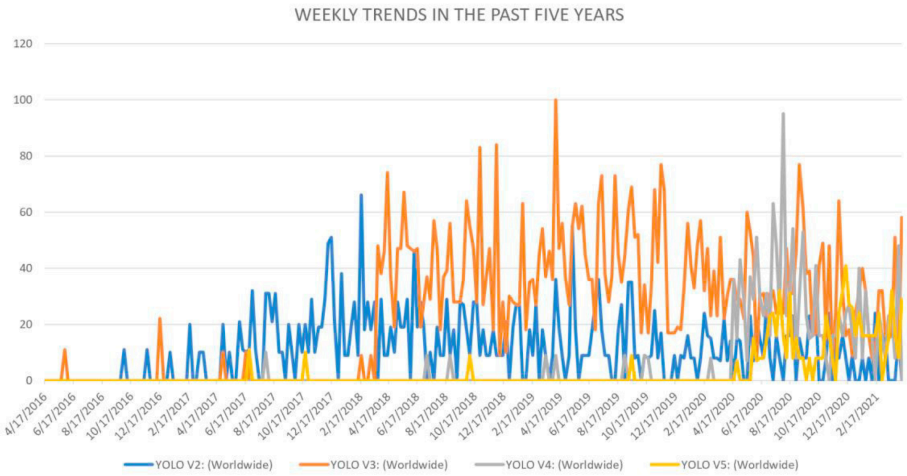

2.1.1.1. ábra A YOLO verziók népszerűsége[1]

Nem részletezném hosszan hogy a tanítási folyamat hogyan működik. Mint általánosan a CNN-ek tanításakor az adatok átméretezésre, illetve normalizálásra kerülnek, majd ismétlődő tanítási ciklusok során a YOLO súlyokat tanít[2]. A YOLO esetében a gyors és hatékony objektumdetektáláson van a hangsúly, ugyanis a *"You Only Look Once"* mondat egyszerűen annyit jelent, hogy egyszeri megnézése, egyszeri prediktálása egy bizonyos képkockának, ez jelentősen gyorsabb felismerési sebességhez vezet.

Az alábbi 2.1.1.2.-ik ábra szemlétet egy bounding box perdiktálást. Megfigyelhető az ábrán, hogy amint a képkockák végigmennek a YOLO-n, átméreteződnek, lefut rajtuk egyetlen CNN-en, végül egy non-max supression(NMS) algoritmust, amelynek a lényege hogy a duplikált, egymáson elhelyezkedő detektálásokat törli, csak a legvalószínűbbet tartja meg[2]. Eredményként pedig visszatérít detektálásonként egy bounding boxot (határoló doboz, keret), illetve hozzájuk tartozó osztályt és a detektálás konfidenciáját (pontosságának arányát)[2].

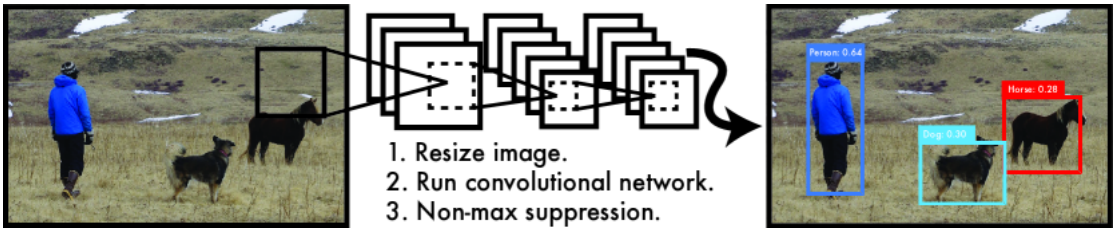

2.1.1.2. ábra A YOLO képkockánkénti működése[2]

A 2.1.1.3.-as ábrán látható, hogy mi történik egyetlen fotóval amin objektumokat kell detektálni. A YOLO felossza a bemeneti képet SxS méretű gridekre(rácsokra), minden gridben lévő képkockára prediktál B bounding boxot, azoknak a konfidencia értékeit (azaz tartalmaz-e objektumot vagy sem), továbbá C darab osztály perdikcióját (vagyis az a bizonyos objektum ha van, akkor milyen valószínűséggel tartozik egyenként az osztályokhoz), ez a grid-based algoritmus[2]. Ezek a predikciók egy tenzorban lesznek eltárolva, aminek a méretét a 2.1.1.4.-es ábrán lévő képlettel lehet kiszámolni[2].

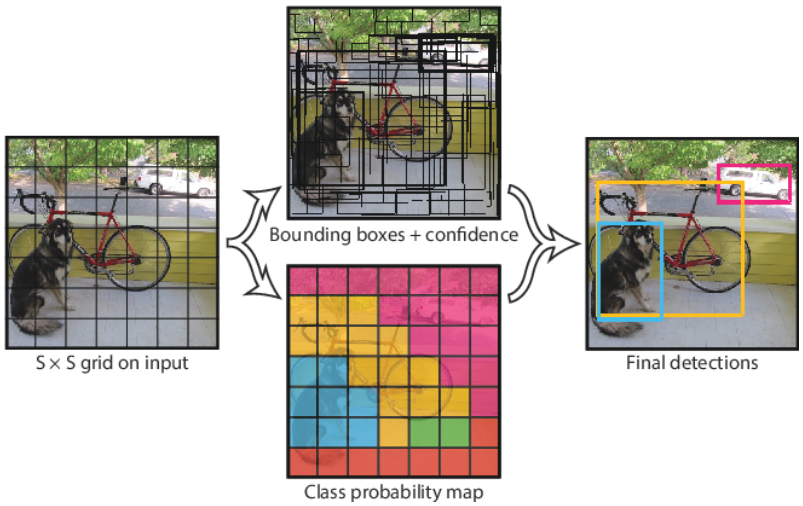

2.1.1.3. ábra A YOLO képfeldolgozása[2]

$$S \times S \times (B \times 5 + C)$$

2.1.1.4. ábra Predikciók mérete[2]

Az egyik legsikeresebb verziója a harmadik verzió (YOLO V3), amely már a fennebbi népszerűségi grafikonon is látszik, hogy kiemelkedik a többi közül. Ez a verzió nagy lépés volt az

előző kettőhöz képest. Ámbár kicsit mélyebb hálót alkalmaztak ennél a verziónál, sikerült fejleszteni az alacsonyabb erőforrásigényű és hatékonyabb működést, ezek mellett ráadásul az eddigi leggyorsabb detektálási idővel rendelkezik és sokkal pontosabb az elődeihez képest[3]. A 2.1.1.5.-ik ábrán egy grafikon látható, amelyen látszik, hogy a YOLO V3 elhagyja detektálási sebességben a 2018-as kortárs hálóit, hasonló átlag pontossági metrika mellett. Látható, hogy a *"legkisebb"* 320x320-as harmadik generációs YOLO háló a leggyorsabb 22 milliszekundumos sebességgel, viszonylag kicsi 28.2 mAP-s (mean Average Precision) pontossággal[3]. A legnagyobb 608x608-as modell pedig ámbár nagyon jó 33.0 mAP-s pontosságot produkált, mégis a töredék idejét futja a nála pontosabb vagy nagyjából megegyező pontosságú, de egyébként nagyobb RetinaNet, SSD, DSSD és FPN hálóknál[3].

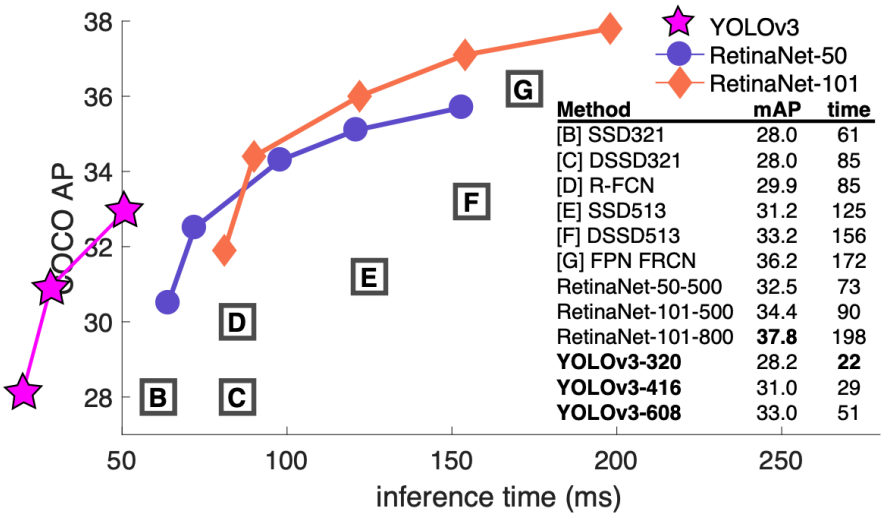

2.1.1.5. ábra YOLO V3 összehasonlítása[3]

A következő verzió a YOLO V4 , amely már nem volt akkora ugrás a harmadik verzióhoz képest, kevés dolgot változtattak meg, például a YOLO V3 CNN-ét, a Darknet-53-at (53 konvolúciós réteg) megörökölte, épp a CSP (Cross Stage Partial) vezették be mellé, amely hatékonyabban kezeli az információ áramlását a hálózatban, így lett a háló neve CSPDarknet-53[1]. Ennek a fejlesztésében már nem fordítottak akkora figyelmet az alacsonyabb erőforrásigényre, ennek eredménye egy ugyan sokkal pontosabban és gyorsabban detektáló algoritmus lett, viszont a hozzáadott adat összehasonlító algoritmusok, illetve az összetettebb szoftver architektúra több számítási erőforrást igényel[1]. A YOLO V4 kb. 65 FPS-es (Framerates Per Second, Képkocka másodpercenként) sebességű valós idejű képfeldolgozással, egy NVIDIA Tesla V100-as grafikus gyorsítóval 43.5% AP-s (Average Precision) pontosságot tudott elérni. A következő 2.1.1.6.-ik

ábrán az figyelhető meg, hogy a YOLO V4 kétszer gyorsabban fut, mint a EfficientDet nevű háló, mindemellett hasonló teljesítménnyel[4]. Ez a verzió az előző harmadik verzióhoz képest 10% és 12% javulást hozott mind az AP, mind az FPS szempontjából[4].

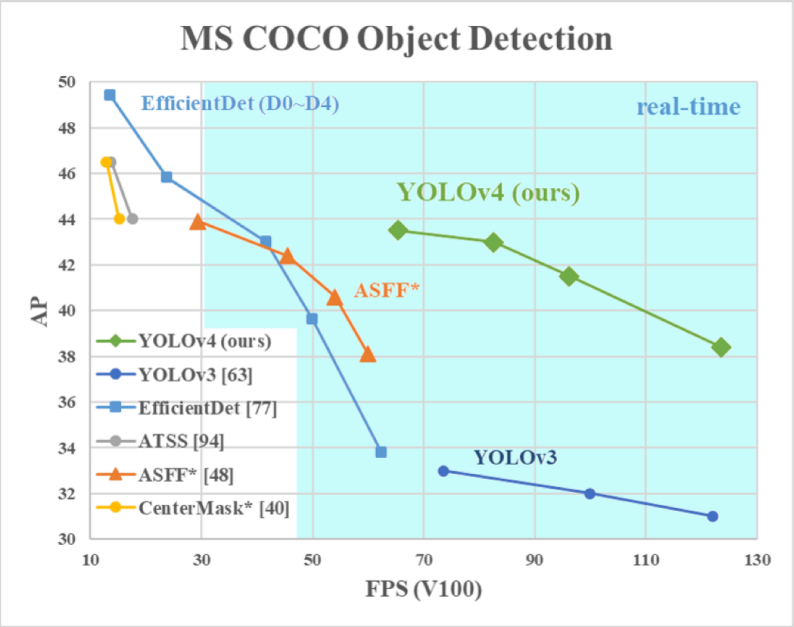

2.1.1.6. ábra YOLO V4 összehasonlítása[4]